

# **Opracowanie i implementacja podstaw optymalnego przechowywania i transferowania danych medycznych (ontologie)**

Patryk Bąk, Marek Kendziorek, Wojciech Inglot

AGH Kraków, 2013

## 1 Abstrakt

**Wprowadzenie:** Systemy medyczne należą do jednych z najbardziej rozbudowanych systemów w branży IT. Cechują się one nie tylko ogromnymi ilościami danych, które przetwarzają, ale również bardzo dużą złożonością budowy tych danych oraz relacji, które między nimi zachodzą. Własnie branża e-health jako jedna z pierwszych zainteresowała się zastosowaniem ontologii oraz ich reprezentacji w zagadnieniu reprezentowania danych. Niniejszy artykuł porusza problem zastosowania optymalnych technologii i metodologii do implementacji systemu opartego o ontologię z naciskiem na przechowywanie oraz transfer ontologii.

**Rozwiązanie:** Zaproponowane przez nas rozwiązanie problemu oparte zostało na języku programowania java oraz opartych na nim technologiach i narzędziach. Do transferu danych wykorzystano FUSEKI, które oferuje transfer danych protokołem REST z wykorzystaniem języka zapytań SPARQL. Dodatkowo przy definiowaniu ontologii zaproponowano wykorzystanie opartego i interfejsy i stałe słownika danych.

**Wnioski:** Zaproponowana przez nas implementacja reprezentacji oraz transferu danych medycznych posiada wiele cech pożądanych przy projektowaniu tego typu systemów. Rozwiązanie to cechuje się bardzo dużą skalowalnością zarówno od strony wielkości samego systemu jak i możliwości rozbudowy przechowywanych w nim danych. Zastosowanie architektury typu SOA przy budowie systemu medycznie pozwala na łatwą, modułową rozbudowę takiego systemu oraz ułatwioną integrację z innymi systemami medycznymi, zupełnie niezależnymi od siebie.

## 2 Wstęp

### 2.1 Ontologia

Ontologia jest formalną reprezentacją pewnej dziedziny wiedzy. Składają się na nią zapis zbiorów pojęć i relacji między nimi. Zapis ten tworzy schemat pojęciowy, który jest opisem danej dziedziny wiedzy. Może służyć jednocześnie jako podstawa do wnioskowania o właściwości opisywanych ontologią pojęć.

Pod pojęciem ontologii mogą się kryć różne struktury wiedzy. Ich przeznaczenie czy zakres stosowania może być wieloraki.

Ontologie możemy podzielić ze względu na stopień ich formalizacji:

- nieformalne
  - predefiniowane słownictwo
  - słowniki
  - tezarusy
  - taksonomie
- formalne
  - ontologie oparte na danych
  - ontologie oparte na logice

Podział następuje także ze względu na zakres stosowania:

- ontologie wysokiego poziomu (*upper ontologies*)
- ontologie dziedzinowe (*domain ontologies*)
- ontologie aplikacyjne

Istnieje szereg języków pozwalających na zapis lub wspierających ontologie:

- OWL (*Ontology Web Language*)
- RDF (*Resource Description Framework*)
- RDF Vocabulary Description Language (RDF Schema, RDFS)
- OCML (Operational Conceptual Modeling Language)
- XML (Extensible Markup Language)

### 2.2 OWL

OWL (Ontology Web Language) jest opartym na składni XML językiem służącym do opisu ontologii. Stanowi on rozszerzenie języka RDF (Resource Definition Language). Istnieją 3 odmiany OWL: OWL Lite, OWL DL oraz OWL Full. W 2004 roku język ten został uznany za standard przez organizację W3C.

OWL został stworzony do przetwarzania informacji o obiektach oraz relacji między nimi, nie do przechowywania tych informacji w formie czytelnej dla człowieka. OWL jest zbudowany na bazie RDF, tak więc języki te są ze sobą w pełni kompatybilne. OWL posiada jednak znacznie mocniejszą składnię.

Do elementów języka OWL należą takie atrybuty jak:

- Class - definiuje grupę indywidualności, które posiadają pewne wspólne cechy. Klasy można organizować w hierarchie za pomocą atrybutu `subClassOf`.
- `rdf:Property` - określa pewne relacje między indywidualnościami np. samochód może posiadać drzwi, osoba może posiadać dziecko albo rodzica.
- `rdfs:domain` - ogranicza indywidualności, do których można zastosować relację (property). Jeżeli relacja łączy jedną indywidualność z drugą, i jednocześnie posiada ona domenę na określonej klasie, to obie indywidualności muszą należeć do tej klasy.
- `rdfs:range` - ogranicza nie tylko indywidualności, ale także wartość relacji (property)
- Individual - indywidualności są instancjami klas, które są połączone pewnymi relacjami (property).

Wszystkie powyższe atrybuty są częścią specyfikacji OWL Lite.

### 2.3 Protege

Protege jest otwarto-źródłowym narzędziem stworzonym przez Stanford Medical Informatics. Jak przy większości narzędzi modelujących, architektura Protege jest przejrzyste podzielona na dwie części - model i widok. Modele są wewnętrzną reprezentacją mechanizmu ontologii i baz wiedzy. Widoki zapewniają interfejs użytkownika, dzięki któremu można wyświetlać i manipulować modelami.

Protege posiada możliwość wczytania, edycji i zapisywania w wielu popularnych dla ontologii formatach, np:

- RDF
- OWL
- XML
- UML
- Bazy relacyjne

### 2.4 SPARQL

SPARQL jest językiem zapytań RDF, czyli pozwala na wyciąganie lub manipulowanie danymi w bazie danych składającej dane w formacie RDF (eng. Resource Description Framework). SPARQL pozwala również na pracę na danych w formacie pochodnym od formatu RDF, np. OWL, jednak z pewnymi ograniczeniami. SPARQL operując na danych w formacie OWL musi pominać elementy języka które nie mają przełożenia na format RDF.

Konstrukcja zapytań opiera się o zestaw trzech parametrów:

- spójnika (eng. conjunction)
- alternatywy (eng. disjunction)
- wzorzec (opcjonalnie) (eng. pattern)

Idea jaka przyświecała twórcom SPARQL określała go jako przełom w tworzeniu internetu czytelnego dla maszyn. Jeżeli format ten przyjmie się jako standard otrzymamy uniwersalny sposób otrzymywania informacji z internetowych „skupisk” danych, co da nowe możliwości łączenia danych z różnych źródeł.

### 2.5 REST

REST jest protokołem komunikacji między aplikacjami, który tak naprawdę jest tylko pewną dodatkową warstwą nałożoną na protokół HTTP. Budowanie zapytań restowych z poziomu języków programowania jest tak samo proste, jak zrozumienie działania protokołu HTTP. Istnieje wiele bibliotek i prostych frameworków do budowania serwisów, odbierających i wysyłających zapytania HTTP. Należą do nich np Jersey-RS, czy zbudowana na jego bazie trochę większa biblioteka Apache CXF. Biblioteka Fuserki, będąca częścią specyfikacji Apache Jena oferuje możliwość transferu danych właśnie protokołem REST, przy użyciu języka zapytań SPAQRL.

Ze względu na swoją prostotę i oparcie o standard HTTP, wybór tego protokołu jako sposobu komunikacji między aplikacjami jest bardzo dobrą decyzją. Umożliwia to znakomitą skalowalność naszego systemu, poprzez rozdzielenie go na szereg indywidualnych aplikacji, które nie muszą być napisane przy użyciu tej samej technologii, muszą jedynie współdzielić tą metodę komunikacji oraz ewentualnie sposób serializacji danych.

## 2.6 Fuseki

Fuseki jest to serwer HTTP w standardzie REST przyjmujący zapytania HTTP zawierające w parametrach zapytania SPARQL. Dzięki niemu możemy w ustandaryzowany sposób pobierać lub manipulować danymi w modelu OWL lub RDF.

Fuseki jest jednym z subsystemów systemu Jena. Twórcy zadbali o to żeby serwer SPARQL udało się włączyć nie tylko poprzez konsolę, ale również bezpośrednio z aplikacji JAVA z wykorzystaniem biblioteki Jena.

### 3 Implementacja rozwiązań

Rozwiązanie zaprezentowane w niniejszym artykule zostało napisane w języku Java, z wykorzystaniem Ontology API biblioteki Apache Jena. Biblioteka ta pozwala na mapowanie różnego rodzaju reprezentacji ontologii na klasy Java. Do transferowania naszych danych wykorzystamy bibliotekę Apache CXF, a dokładniej jej moduł REST, który pozwoli nam na przesyłanie zserializowanych danych przez protokół HTTP.

#### 3.1 Reprezentacja danych

Ontology API biblioteki Apache Jena pozwala między innymi na budowanie oraz importowanie modeli ontologii. Stworzenie nowego modelu ontologii oraz zaimportowanie do niego już istniejącej ontologii zapisanej w formacie OWL przedstawiono na rysunku. Przykładowy graf wygenerowany z części ontologii widoczny jest na rysunkach 1 oraz 2

#### 3.2 Transfer danych

W projekcie uruchomiony został serwer HTTP Fuseki. Pozwala on na przechowywanie i udostępnienie danych wczytanych z plików OWL poprzez zapytania HTTP. W jego wewnętrznej bazie danych budowane są grafy do których aplikacje klienckie odwołują się w zapytania SPARQL.

**Instalacja** Instalacja Jena i Fuseki ogranicza się do dodania do zmiennych środowiskowych ścieżek do paczek.

```
export JENA=
    /Users/XXXX/Fuseki/apache
    -jena-2.11.0/
export FUSEKI=
    /Users/XXXX/Fuseki/jena
    -fuseki-1.0.0/
```

**Uruchomienie serwera** Standardowo serwer FUSEKI uruchamiany jest pod wirtualną domeną „localhost”i na porcie 3030.

Uruchomienie serwera FUSEKI:

```
./fuseki-server --update
--loc=/Users/~MyTDB/ /ds &
```

**Ładowanie pliku z ontologią** Załadowanie pliku OWL (poprzez konsolową komendę):

```
./s-put
http://localhost:3030/ds/data
default
/Users/XXXX/RIMV3OWL.owl
```

#### Tworzenie zapytania SPARQL

Wysłanie zapytania SPARQL wypisującego „koncepty”z załadowanego grafu:

1. Tworzenie zapytania.


```
select distinct ?Concept
where {[ a ?Concept]}
```

2. Tworzenie zapytania HTTP POST, gdzie:

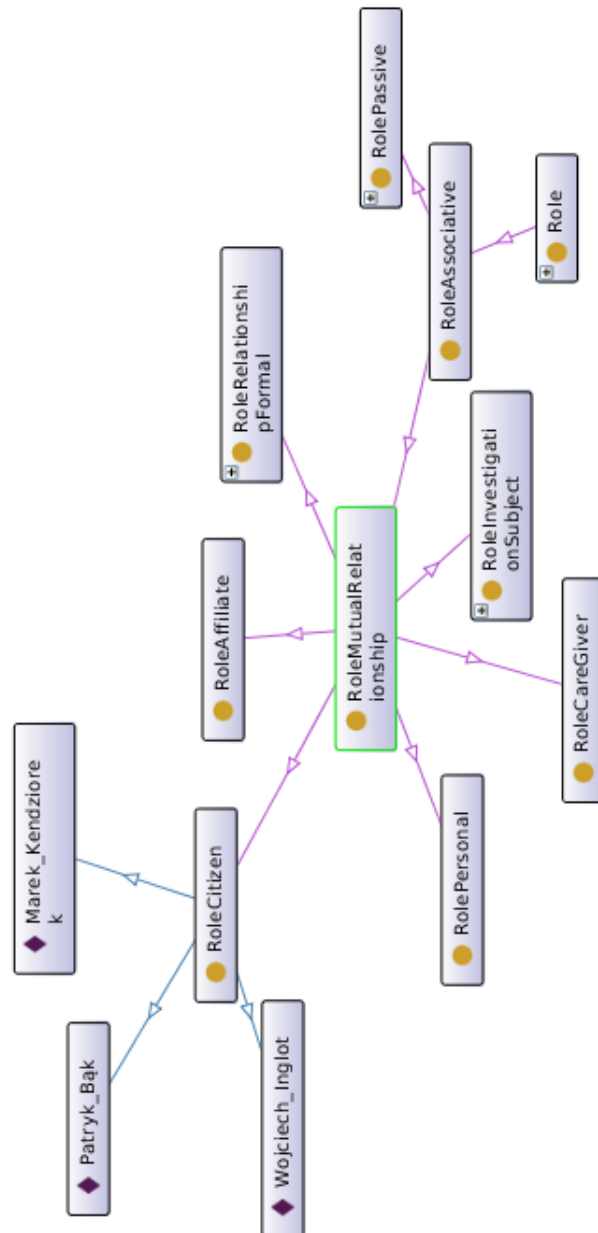
- jako URI podajemy sufix prowadzący do punktu końcowego (eng. endpoint) i dokładamy końcówkę /query
- w parametrze POST/GET „query”podajemy stworzone zapytanie
- opcjonalne parametry: output (np. „json”), default-graph-uri

3. W efekcie otrzymujemy zapytanie (dla punktu końcowego „ds”:

```
http://localhost:3030/ds/sparql?
query=select+distinct++%3FConcept
+where+%7B%5B%5D+a+%3FConcept%7D
&default-graph-uri=
&output=json
```



Rysunek 1. Przykład Ontologii Opartej o HL7 (EntityPlace)



**Rysunek 2.** Przykład Ontologii Opartej o HL7 (Role)



## 4 Wykorzystanie

Poniżej zamieszczone są przykładowe zapytania sparql do pobierania informacji z grafów przedstawionych na rysunku 1 i rysunku 2.

**Wyszukiwanie węzłów-rodzeństw (poprzez użycie „właściwości sameAs”** Zapytanie:

```
PREFIX rdf:
    <http://www.w3.org/
    1999/02/22-rdf-syntax-ns#>
PREFIX rdfs:
    <http://www.w3.org/
    2000/01/rdf-schema#>
PREFIX owl:
    <http://www.w3.org/
    2002/07/owl#>
PREFIX HL7:
    <http://sim.ontology/HL7#>
SELECT ?subject ?object
    WHERE { ?subject
        owl:sameAs ?object
    }
```

Wynik:

```
{
  "head": {
    "vars": [ "subject" ,
              "object" ]
  } ,
  "results": {
    "bindings": [
      {
        "subject": { "type":
                      "uri" , "value":
                      "http://sim.ontology/
                      HL7#Krakow" } ,
        "object": { "type":
                     "uri" , "value":
                     "http://sim.ontology/
                     HL7#Warszawa" }
      } ,
      {
        "subject": { "type":
                      "uri" , "value":
                      "http://sim.ontology/
                      HL7#Marek_Kendziorek"
                    } ,
        "object": { "type":
                     "uri" , "value":
                     "http://sim.ontology/
                     HL7#Wojciech_Inglot"
                    }
      } ,
      {
        "subject": { "type":
                      "uri" , "value":
                      "http://sim.ontology/
                      HL7#Patryk_Bak" } ,
        "object": { "type":
                     "uri" , "value":
                     "http://sim.ontology/
                     HL7#Wojciech_Inglot"
                    }
      } ,
      {
        "subject": { "type":
                      "uri" , "value":
                      "http://sim.ontology/
                      HL7#Mazowsze" } ,
        "object": { "type":
                     "uri" , "value":
                     "http://sim.ontology/
                     HL7#Malopolska"
                    }
      } ,
      {
        "subject": { "type":
                      "uri" , "value":
                      "http://sim.ontology/
                      HL7#Mazowsze" } ,
        "object": { "type":
                     "uri" , "value":
                     "http://sim.ontology/
                     HL7#Podkarpacie"
                    }
      } ,
      {
        "subject": { "type":
                      "uri" , "value":
                      "http://sim.ontology/
                      HL7#Malopolska" } ,
        "object": { "type":
                     "uri" , "value":
                     "http://sim.ontology/
                     HL7#Podkarpacie"
                    }
      }
    ]
  }
}
```

```
HL7#Marek_Kendziorek"
    } ,
    "object": { "type":
                 "uri" , "value":
                 "http://sim.ontology/
                 HL7#Wojciech_Inglot"
               }
  } ,
  {
    "subject": { "type":
                  "uri" , "value":
                  "http://sim.ontology/
                  HL7#Patryk_Bak" } ,
    "object": { "type":
                 "uri" , "value":
                 "http://sim.ontology/
                 HL7#Wojciech_Inglot"
               }
  } ,
  {
    "subject": { "type":
                  "uri" , "value":
                  "http://sim.ontology/
                  HL7#Mazowsze" } ,
    "object": { "type":
                 "uri" , "value":
                 "http://sim.ontology/
                 HL7#Malopolska"
               }
  } ,
  {
    "subject": { "type":
                  "uri" , "value":
                  "http://sim.ontology/
                  HL7#Mazowsze" } ,
    "object": { "type":
                 "uri" , "value":
                 "http://sim.ontology/
                 HL7#Podkarpacie"
               }
  } ,
  {
    "subject": { "type":
                  "uri" , "value":
                  "http://sim.ontology/
                  HL7#Malopolska" } ,
    "object": { "type":
                 "uri" , "value":
                 "http://sim.ontology/
                 HL7#Podkarpacie"
               }
  }
}
```



## 5 Podsumowanie

Zaproponowana przez nas implementacja reprezentacji oraz transferu danych medycznych posiada wiele cech pożądaných przy projektowaniu tego typu systemów. Rozwiązanie to cechuje się bardzo dużą skalowalnością zarówno od strony wielkości samego systemu jak i możliwości rozbudowy przechowywanych w nim danych. Zastosowanie architektury typu SOA przy budowie systemu medycznego pozwala na łatwą, modułową rozbudowę takiego systemu oraz ułatwioną integrację z innymi systemami medycznymi, zupełnie niezależnymi od siebie. Idąc dalej można skorzystać również z możliwości oferowanych przez narzędzia jeszcze wyższych rzędów, takie jak szyny biznesowe, dzięki którym integracja mogłaby być jeszcze skuteczniejsza, nie naruszając jednocześnie architektur oraz implementacji poszczególnych systemów.

W kwestii reprezentacji danych, wykorzystanie takiego frameworku jak Apache Jena pozwala na intuicyjne operowanie na dowolnej reprezentacji ontologii, ich rozbudowę w środowisku programowania java, oraz ich graficzną reprezentację. Wykorzystanie tutaj w pracy środowiska java jednocześnie czyni znacznie prostszą integrację tego rozwiązania z opisanym wcześniej mechanizmem transferowania informacji, który również napisany jest w tym języku.

## Literatura

1. Erik Sundvall, Mikael Nystrom, Daniel Karlsson, Martin Eneling, Rong Chen, Hakan Orman: Applying REST architecture to archetype-based electronic health record systems
2. Wiesław Wajs, Krzysztof Rączka, Paweł Stoch, Piotr Kruczek: Integration Platform As Central Service Of Data Replication In Distributed Medical System
3. Bartosz Jędrzejec: Pozyskiwanie wiedzy z dużych zbiorów danych z zastosowaniem adaptacyjnych procedur generowania zapytań, AGH Kraków 2008
4. Dortje Loper, Meike Klettke, Livio Bruder, Andreas Heuer: Enabling flexible integration of healthcare information using entity-attribute-value storage model
5. IHE cross-enterprise document sharing for imaging: interoperability testing software - Rita Noumeir, Berube Renaud - Springer Link database
6. Integrating Clinical Trial Imaging Data Resources Using Service-Oriented Architecture and Grid Computing - Stefan Baumann El-Ghatta, Thierry Cladé, Joshua C. Snyder - Springer Link database
7. Welcome to Health Information Science and Systems - Yanchun Zhang LabKey Server: An open source platform for scientific data integration, analysis and collaboration - Elizabeth K Nelson, Britt Piehler - Springer Link database
8. A database application for pre-processing, storage and comparison of mass spectra derived from patients and controls - Mark K Titulaer, Ivar Siccama - Springer Link database
9. PASSIM – an open source software system for managing information in biomedical studies - Juris Viksna, Edgars Celms - Springer Link database
10. The HL7 Clinical Document Architecture - Robert H Dolin, Liora Alschuler, Calvin Beebe; Journal of the American Medical Informatics Association Volume 8 Number 6
11. The HL7 Clinical Document Architecture, Release 2 - Robert H Dolin, Liora Alschuler, Calvin Beebe; Journal of the American Medical Informatics Association Volume 13 Number 1
12. HL7 Document Patient Record Architecture: An XML Document Architecture Based on a Shared Information Model - Robert H. Dolin, MD, Liora Alschuler, Fred Behlen, PhD, Paul V. Biron, MLIS, Sandy Boyer, RPh; Dan Essin, MD, Lloyd Harding, Tom Lincoln, MD, John E. Mattison, MD, Wes Rishel, Rachael Sokolowski, John Spinosa, MD, PhD, Jason P. Williams, MS
13. HL7 Version 3—An object-oriented methodology for collaborative standards development - George W Beeler A health-care data model based on the HL7 Reference Information Model - Eggebraaten, T.J. Development of a Clinical Data Warehouse for Hospital Infection Control - Mary F Wisniewski, Piotr Kieszkowski, Brandon M Zagorski,
14. The HL7 Reference Information Model Under Scrutiny - Gunther Schadow , Charles N. Mead, D. Mead Walker Biomedical Engineering (Chapter 19 - Toward Multi-Service Electronic Medical Records Structure) - Bilal I. Alqudah, Suku Nair
15. Introduction to: HL7 Reference Information Model (RIM) - Health Level Seven International
16. HL7 RIM: An Incoherent Standard - Barry Smith, Werner Ceusters
17. Redundancy in electronic health records corpora: analysis, impact on text mining performance and mitigation strategies - Raphael Cohen, Michael Elhadad, Noemie Elhadad

18. Initial experience with asynchronous transfer mode for use in medical imaging network - Minh Dovan, Louis M. Humphrey, Geri Cox, Carl E. Ravin
19. A database application for pre-processing, storage and comparison of mass spectra derived from patients and controls - Mark T Titulaer, Ivar Siccama, Lennard J Dekker
20. Adding HL7 version 3 data types to PostgreSQL - Yeb Havinga, Willem Dijkstra, Ander de Keijzer
21. Clinical data integration of distributed data sources using Health Level Seven (HL7) v3-RIM mapping - Teeradache Viangteeravat, Matthew N Anyanwu, Venkateswara Ra Nagisetty, Emin Kuscu, Mark Eijiro Sakauye, Duoqiao Wu
22. Electronic Medical Records vs. Electronic Health Records: Yes, There Is a Difference - Dave Garets and Mike Davis
23. The “New” America Electronic Medical Record (EMR)—Design Criteria and Challenge - Ralph Grams
24. Security of Medical Data Transfer and Storage in Internet. Cryptography, Antiviral Security and Electronic Signature Problems, which Must Be Solved in Nearest Future in Practical Context - Piotr Kasztelowicz, Marek Czubenko, Iwona Zięba
25. Barriers to implement Electronic Health Records (EHRs) - Sima Ajami, Razieh Arab-Chadegani